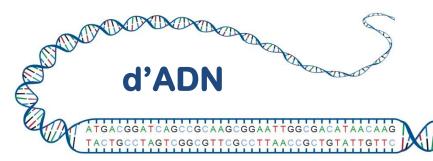
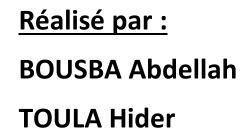


# Mini-projet LU3IN003:

# Alignement de séquences





**Encadré par :** 

**Anne-Elisabeth Falq** 

3ème année Licence Informatique Mono-disciplinaire Groupe n°6

# SOMMAIRE

Definitions :	3
Methode naif :	4
Programmation dynamique	6
Amelioration de la complixité spatiale du calcul de la distance	10
Diviser pour regner	12
Une extension : l'alignement local de séquences (Bonus)	17
COMPADAISON ENTRE LES DEDEORMANICE DES ALGORITHMES	10

# **DEFINITIONS:**

#### Question 1

 $(\bar{\mathbf{X}},\bar{\mathbf{y}})$  est un alignement de  $(\mathbf{X},\mathbf{Y})$  veut dire que :  $\left\{ \begin{array}{l} |\bar{\mathbf{X}}| = |\bar{\mathbf{y}}| \\ \forall \ i \ \in \ [1 \, .. \, |\bar{\mathbf{X}}|], \ \bar{\mathbf{X}}_i \ \neq - \ \mathsf{ou} \ \bar{\mathbf{y}}_i \ \neq - \end{array} \right.$ 

 $(\bar{u},\bar{v})$  est un alignement de (u,v) veut dire que :  $\begin{cases} |\bar{u}| = |\bar{v}| \\ \forall \ i \ \in \ [1..|\bar{u}|], \ \bar{u}_i \ \neq - \ \text{ou} \ \bar{v}_i \ \neq - \end{cases}$ 

Donc:

$$\left.\begin{array}{c} |\bar{x}|=|\bar{y}| \\ |\bar{u}|=|\bar{v}| \end{array}\right\} \qquad \Rightarrow \qquad |\bar{x}.\bar{u}|=|\bar{y}.\bar{v}|$$

Et puisque:

 $\forall i \in [1..|\bar{X}|], \bar{X}_i \neq - \text{ ou } \bar{Y}_i \neq - \text{ et } \forall j \in [1..|\bar{U}|], \bar{U}_j \neq - \text{ ou } \bar{V}_j \neq -$ 

Alors:

$$\forall i \in [1..|\bar{X}.\bar{U}|], (\bar{X}.\bar{U})_k \neq - \text{ ou } (\bar{Y}.\bar{V})_k \neq -$$

Conclusion:

 $(\bar{x},\bar{y}) \text{ et } (\bar{u},\bar{v}) \text{ alignements de resp. } (x,y) \text{ et } (u,v) \quad \Rightarrow \quad (\bar{x}.\bar{u},\bar{y}.\bar{v}) \text{ alignement de } (x.u,y.v)$ 

# Question 2

La longueur maximale d'un alignement (x,y) de longueur respectivement n,m est : n+m

### Exemple:

Soit  $\Sigma = \{A,G,T,C\}$  avec x = GTA et y = AAAAAA donc n = 3 et m = 6, l'alignement de taille maximale est :

$$\bar{x} = GTA---- \bar{y} = ---AAAAAA$$

On a bien n+m = 3+6 = 9 la taille de l'alignement ci-dessus.

# METHODE NAIF:

#### **Question 3**

On sait que la longueur de  $\bar{X}$  après positionnement de k gaps dans x est n+k , en sachant que on ne peut pas changer l'ordre de lettre et que l'ordre des gaps et le même on a :

Le nombre de mots  $\bar{x}$  avec k gaps est :  $C_{n+k}^k$ 

#### **Question 4**

On doit ajouter k' = n+k-m gaps a y

Pour un k donné on a :  $C^k_{n+k} \times C^{k'}_n$  alignements possible

On sait que la taille max d'un alignement est n+m alors  $k \in [0,m]$  donc le nombre d'alignement possible est :

$$\sum_{k=1}^{m} (C^{k}_{n+k} \times C^{k'}_{n}) \quad \text{avec } k' = n+k-m$$

Pour n = 15 et y = 10 on a  $\sum_{k=0}^{10} \frac{(k+15)! \times 15!}{15! \times k! \times (10-k)! \times (k+5)!} = 298199265$  alignements possibles

# **Question 5**

La complexité pour trouver une distance d'édition et trouver un alignement de coût minimal est : le nombre d'alignements possible car il sera obliger énumérer tout les alignements.

Donc : nombre alignement possible qui veut dire  $\Theta(\sum_{k=1}^{m} (\mathbf{C_{n+k}^{k} \times C_{n}^{k'}}))$ 

#### **Question 6**

La complexité spatiale d'un algorithme naïf :

Pour trouver la distance :  $\Theta(1)$  pour la variable dist

Pour trouver un alignement minimale : O(n+m) pour le tableau de taille max n+m

En prenant en considération la pile des appel récursif on est en  $\Theta(\sum_{k=1}^{m} (\mathbf{C}_{n+k}^{k} \times \mathbf{C}_{n}^{k'}))$ 

#### Tache A

Les tests son indiquer sur le fichier testTacheA.py, les résultats son les suivants :

fichier: Instances\_genome/Inst\_0000010\_7.adn

Distance naif: 8 time used is 5.924769 s

fichier: Instances\_genome/Inst\_0000010\_8.adn

Distance naif: 2 time used is 2.388596 s

 $fichier: Instances\_genome/Inst\_0000010\_44.adn$ 

Distance naif: 10 time used is 0.032060 s

Distance naif: 6 time used is 10.652283 s

fichier: Instances\_genome/Inst\_0000012\_56.adn

Distance naif: 9

time used is 77.781131 s

Plus grande instance execute: Instances\_genome/Inst\_0000500\_8.adn

Consumation mémoire: pour toute instance la consommation est de 0.1% mais la pile des appels récursifs ne peut pas exécuteur une instance plus grande que n = 500 qui est cohérent car la fonction est en  $\Theta(1)$  mais en prenant compte de la pile des appels récursif on est en  $\Theta(\sum_{k=1}^{m} (C_{n+k}^{k} \times C_{n}^{k'}))$ 

#### Complexité:

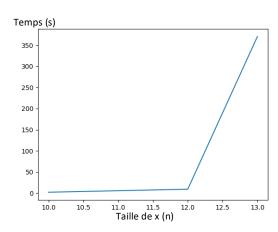


Figure 1 -Performance de la méthode DIST\_NAIF

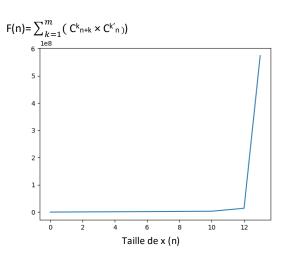


Figure 2 - Attente Théorique

En considérant le graphe de la Figure 2 a partir de n=10 on remarque que c'est exactement le comportement de DIST\_NAIF.

# PROGRAMMATION DYNAMIQUE

#### 1. CALCUL DE LA DISTANCE

#### Question7

 $(\bar{\mathbf{U}},\bar{\mathbf{V}})$  est un alignement de  $(\mathbf{U}_{[1..i]},\mathbf{V}_{[1..j]})$  veut dire que :  $\forall i \in [1..|\bar{\mathbf{U}}|], \bar{\mathbf{U}}_i \neq -$  ou  $\bar{\mathbf{V}}_i \neq -$  donc :

Si on a  $\bar{u}_I = -$  alors  $\bar{v}_I$  doit être le dernier caractère de v donc  $v_j$  car on ne peut pas changer l'ordre des caractères. Et donc si on a  $\bar{v}_I = -$  alors  $\bar{u}_I = u_i$ 

Puis si on a  $\bar{u}_1 \neq -$  ou  $\bar{V}_1 \neq -$  on aura  $\bar{u}_1 = u_i$  et  $\bar{V}_1 = v_i$ 

#### **Question8**

$$C(\bar{u},\bar{v}) = \begin{cases} C(\bar{u}_{[1..l-1]}, \, \bar{v}_{[1..l-1]}) + C_{ins} & \text{si } \bar{u} \text{ } l = - \\ \\ C(\bar{u}_{[1..l-1]},\bar{v}_{[1..l-1]}) + C_{del} & \text{si } \bar{v} \text{ } l = - \\ \\ C(\bar{u}_{[1..l-1]},\bar{v}_{[1..l-1]}) + C_{sub}(\bar{u}\text{ } l,\bar{v}\text{ } l) & \text{sinon} \end{cases}$$

#### Question9

On sait que D(i,j) et la distance minimale et que le cout de la case (i,j )est obtenue a partir des case (i,j-1), (j-1,i-1), (i-1,j)

Donc:

$$D(i,j) = min \begin{cases} D(i-1,j-1) + C_{sub}(x_i,y_j) \\ D(i-1,j) + C_{del} \\ D(i,j-1) + C_{ins} \end{cases}$$

#### Question10

 $D(0,0) = d(x_{[1..0]}, y_{[1..0]}) = d(\emptyset,\emptyset) = 0$  car la distance entre deux mots vide est nulle.

#### Question11

On sait que D(0,j) est obtenus a partir des case (-1,j)(-1,j-1)(0,j-1) comme la position -1 d'une lettre d'un mot n'existe pas ,  $D(0,j-1) + C_{ins}$  est la seule option donc :

$$\begin{split} &D(0,j) = &D(0,j-1) + C_{ins} \\ &D(0,j) = &D(0,j-2) + 2 \times C_{ins} \\ &\cdot \\ &\cdot \\ &\cdot \\ &D(0,j) = &D(0,0) + j \times C_{ins} \end{split}$$

et selon la question 10 on a D(0,0) = 0 donc

$$D(0,j)=j\times C_{ins}$$

De la même façon pour i

$$D(i,0) = i \times C_{del}$$

#### Question12

```
Entrée: x et y deux mots

Sortie: distance entre x et y

T = tableau indexé par [o..n][o..m]

T[o][o] = o;

Pour i de 1 à n+1 faire

______ T[i][o] = i × C_{del}

Pour j de 1 à m+1 faire

______ T[o][j] = j × C_{ins}

Pour i de 1 à n+1 faire

______ Pour j de 1 à m+1 faire

______ Pour j de 1 à m+1 faire

______ T[i][j] = min (T[i-1][j-1]+C_{sub}(X_{i-1}, Y_{i-1}),

T[i][j-1]+C_{ins}, T[i-1][j] + C_{del})

retourner T[n][m]
```

#### Question13

La complexité spatiale de DIST\_1 est  $\Theta(\mathbf{n} \times \mathbf{m})$  car dans tout les cas l'algorithme parcours et sauvegarde toute la matrice qui contient  $\mathbf{n} \times \mathbf{m}$  cases.

#### Question14

La complexité temporelle de DIST\_1 est  $\Theta(n \times m)$  car on parcours un tableau de deux dimension n et m pour calculer la distance minimale de chaque combinaison.

#### 2. CALCUL D'UN ALIGNEMENT OPTIMAL

```
Soit (i,j) \in [0..n] \times [0..m] Mq Si j>0 et D(i,j) = D(i,j-1) + C<sub>ins</sub> \Rightarrow \forall (\bar{u},\bar{v}) \in Al^* (i,j-1), (\bar{u}.-,\bar{v}\cdot\gamma_j) \in Al^* (i,j):
D(i,j) = D(i,j-1) + C_{ins} = d(x_{[1..i]},y_{[1..j-1]}) + C_{ins}
= C(\bar{u},\bar{v}) + C_{ins} \quad (\bar{u},\bar{v}) \in Al^* (i,j-1)
= C(\bar{u}.-,\bar{v}\cdot\gamma_j) \quad \textit{cf Question 8}
On a D(i,j) = d(x_{[1..i]},y_{[1..j]}) = C(\bar{u}.-,\bar{v}\cdot\gamma_j) \quad \text{alors } (\bar{u}.-,\bar{v}\cdot\gamma_j) \in Al^* (i,j)
```

#### Question16

```
SOL_1
               Entrée : x et y deux mots
                              T tableau de deux dimension [o..n] × [o..m] remplis par DIST_1
               Sortie: alignement minimale de (x,y)
               \bar{x}=\emptyset, \bar{y}=\emptyset, i=n, j=m
               tantque (j>o) or (i>o) faire
                              si (j>o) and T[i][j] = T[i][j-1] + C_{ins} alors
                                            \bar{X} = -.\bar{X}
                                            \bar{y} = y_{j-1}.\bar{y}
                              si_{j}(i>0) and T[i][j] = T[i-1][j] + C_{del} alors
                                            y=−.y
                                            \mathbf{\bar{X}} = \mathbf{X}_{i-1}.\mathbf{\bar{X}}
                              si (j>o) and (i>o) and T[i][j] = T[i-1][j-1] + C_{sub}(x_{i-1}, y_{j-1}) alors
                                            \boldsymbol{\bar{X}} = \boldsymbol{\chi_{i\text{--}1}}.\boldsymbol{\bar{X}}
                                            \boldsymbol{\bar{y}} \! = \! y_{j\text{--}1}.\boldsymbol{\bar{y}}
               <u>ret</u>ourner (X, y)
```

#### **Question17**

La complexité de PROG\_DYN est en  $\Theta(n \times m)$  car on doit parcourir toutes les case de la matrice pour la construire dans Dist\_1 en  $\Theta(n \times m)$  puis appliquer SOL\_1 pour trouver l'alignement minimale en  $\Theta(n \times m)$ 

#### Question18

La complexité spatiale de SOL\_1 est O(n+m) et de DIST\_1 est  $O(n\times m)$ 

Alors PROG\_DYN est en O(n×m)

#### Tache B

Les tests son indiquer sur le fichier testTacheB.py, les résultats son les suivants :

fichier: Instances\_genome/Inst\_0000010\_7.adn

Distance1 + Align 1: (8, 'TGGG-TG-CTAT', '-GGGGT-TCTAT') time used is 0.000082 s

fichier: Instances\_genome/Inst\_0000010\_8.adn

Distance1 + Align 1: (2, 'AACTGTCTTT', 'AACTGT-TTT') time used is 0.000076 s

fichier: Instances\_genome/Inst\_0000010\_44.adn

Distance1 + Align 1: (10, 'TATATGAGTC', 'TAT-T---T-') time used is 0.000113 s

fichier: Instances\_genome/Inst\_0000012\_32.adn

Distance1 + Align 1: (6, 'CCATTGATTTTC', 'C-ATTGATT-T-') time used is 0.000089 s

fichier: Instances\_genome/Inst\_0000012\_56.adn

Distance1 + Align 1: (9, 'GCTTAACTAACG', 'GCTAAACTA-CT') time used is 0.000097 s

fichier: Instances\_genome/Inst\_0000100\_7.adn

Distance1 + Align 1: (62, 'TGGGTGCTA....-CCTCAGT', 'TGGGTGCA....-TCCTCA-T') time used is 0.004208 s

fichier: Instances\_genome/Inst\_0000500\_88.adn

Distance1 + Align 1: (296, 'TGT-...GAATTTCCA-G', '-GTTCTCG-...AATTT--AAG') time used is 0.101040 s

fichier: Instances\_genome/Inst\_0002000\_44.adn

Distance1 + Align 1: (1078, 'TATATGA...-TGTCAGT', '-ATATGAGT...GTGTCAGA') time used is 1.669113s

Plus grande instance execute: Instances\_genome/Inst\_0020000\_5.adn
Pour l'instance "Instances\_genome/Inst\_0020000\_5.adn":

Consommation mémoire pour DIST1 : 69% soit 11,2 GB.
Consommation mémoire pour PROG\_DYN : 85% soit 13,9 GB.

#### Complexité:

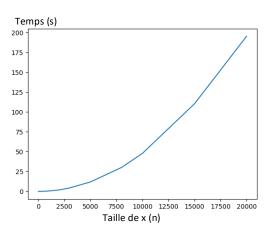


Figure 3 - Performance PROG\_DYN

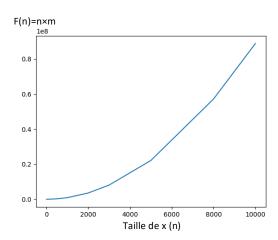


Figure 4 - Attente Théorique

On remarque que la complexité calculé expérimentalement (Figure 3 ) est exactement le comportement qu'on attendait de PROG DYN théoriquement (Figure 4).

# AMELIORATION DE LA COMPLIXITE SPATIALE DU CALCUL DE LA DISTANCE

#### **Question 19**

Parce que la valeur de D(i,j) est obtenu a partir de 3 valeurs D(i-1,j-1),D(i,j-1),D(i-1,j) qui se trouve a la ligne i et la ligne i-1 alors on peut utilisé seulement une matrice de deux lignes pour améliorer la complexité spatiale.

#### **Question 20**

```
DIST_2

Entrée : x et y deux mots

Sortie : distance entre x et y

T = tableau indexé par [o..1][o..m]

T[o][o] = o;

Pour j de 1 à m+1 faire

T[o][j] = j × C<sub>ins</sub>

Pour i de 1 à n+1 faire

T[1][o] = i × C<sub>del</sub>

Pour j de 1 à m+1 faire

T[1][j] = min (T[o][j-1]+C<sub>sub</sub>(X<sub>i-1</sub>,Y<sub>i-1</sub>),

T[1][j-1]+C<sub>ins</sub>, T[o][j] + C<sub>del</sub>)

Pour j de o à m faire

T[o][j] = T[1][j]

retourner T[1][m]
```

#### Tache C

Les tests son indiquer sur le fichier testTacheC.py, les résultats son les suivants :

fichier: Instances\_genome/Inst\_0000010\_7.adn

Distance methode 2:8 time used is 0.000074 s

fichier: Instances\_genome/Inst\_0000010\_8.adn

Distance methode 2: 2 time used is 0.000070 s

 $fichier: Instances\_genome/Inst\_0000010\_44.adn$ 

Distance methode 2 : 10 time used is 0.000047 s

fichier: Instances\_genome/Inst\_0000012\_32.adn

Distance methode 2:6 time used is 0.000074 s

fichier: Instances\_genome/Inst\_0000012\_56.adn

Distance methode 2: 9 time used is 0.000088 s

fichier: Instances\_genome/Inst\_0000100\_7.adn

Distance methode 2:62 time used is 0.004237 s

fichier: Instances\_genome/Inst\_0000500\_88.adn

Distance methode 2: 296 time used is 0.102112 s

 $fichier: Instances\_genome/Inst\_0002000\_44.adn$ 

Distance methode 2: 1078 time used is 1.608261 s

En comparant la consommation mémoire pour la même instance "Instances\_genome/Inst\_0020000\_5.adn":

Consommation mémoire pour DIST1 : 69% soit 11,2 GB. Consommation mémoire pour DIST2 : 17,5% soit 2,8 GB.

On confirme que DIST\_2 est meilleur que DIST\_1 en complexité spatiale.

#### Complexité:

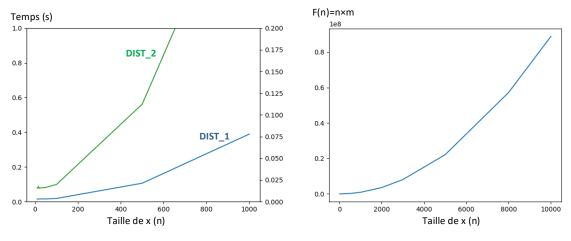


Figure 5 - Comparaison entre dist1 et dist2

Figure 6 - Attente Theorique

L'attente théorique **O(n×m)**représenté dans la figure 6 est bien la même pour la complexité calcule expérimentalement DIST\_1 (voir entre 0,1000) par contre pour DIST\_2 est supérieur a **n×m** mais c'est logique car elle prend en compte le temps d'exécution des opération de décalage.

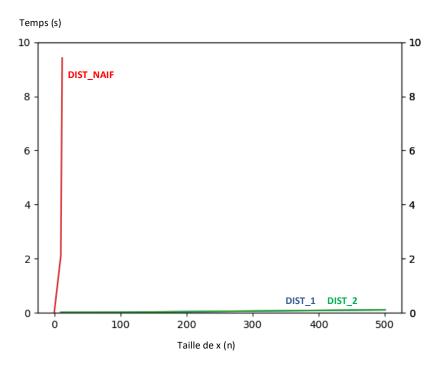


Figure 7 - Comparaison DIST\_NAIF, DIST\_1, DIST\_2

En comparant DIST\_NAIF avec DIST\_1 et DIST\_2 on voit clairement la différance dans la performance des fonctions.

# **DIVISER POUR REGNER**

#### **Question 21**

```
Entrée : entier k

Sortie : mot constituer de k gaps

out = Ø

Pour i de 1 à k faire

out = out.—

retourner out
```

```
Align_lettre_mot

Entrée : x et y deux mots avec x de taille 1

Sortie : alignement minimale de (x,y)

\bar{y} = y, \bar{x} = x, min = +\infty, pos = -1

Pour j de 1 à m faire

\begin{array}{c} \text{si } C_{\text{sub}}(x_{o_i}y_j) < \text{min alors} \\ \text{min = } C_{\text{sub}}(x_{o_i}y_j) \\ \text{pos = i} \\ \text{si } (\text{min + (m-1)} \times C_{\text{ins}}) > (C_{\text{del}} + \text{m} \times C_{\text{ins}})) \text{ alors} \\ \bar{x} = \bar{x}.\text{mot\_gaps}(m) \\ \bar{y} = \bar{y}.- \\ \frac{\text{sinon}}{\bar{x} = \text{mot\_gaps}(\text{pos}).\bar{x}.\text{mot\_gaps}(\text{m-pos})} \\ \frac{\text{retourner } (\bar{x}, \bar{y})}{\bar{y}} \end{array}
```

#### **Question 23**

 $(\bar{X}_1,\bar{y}_1)$  est un alignement optimale de  $(x^1,y^1)$  est :

$$\bar{x}_1 = BAL$$
  
 $\bar{y}_1 = RO-$ 

 $(\bar{X}_2, \bar{Y}_2)$  est un alignement optimale de  $(x^2, y^2)$  est :

$$\bar{x}_2 = LON - \bar{y}_2 = --ND$$

Supposant que  $(\bar{X}_1.\bar{X}_2,\bar{Y}_1.\bar{Y}_2)$  est optimale . on a  $C(\bar{X}_1.\bar{X}_2,\bar{Y}_1.\bar{Y}_2)=22$ 

$$\bar{x}_1.\bar{x}_2 = \text{BALLON-} \\ \bar{y}_1.\bar{y}_2 = \text{RO---ND}$$

or il existe un alignement du même taille  $(\bar{X}_3.\bar{X}_3)$  tq  $C(\bar{X}_3.\bar{X}_3) = 17 < 22 < C(\bar{X}_1.\bar{X}_2,\bar{Y}_1.\bar{Y}_2)$  ABS.

$$\bar{x}_3$$
= BALLON-  
 $\bar{y}_3$ = R---OND

Donc par l'absurde  $(\bar{X}_1.\bar{X}_2,\bar{y}_1.\bar{y}_2)$  n'est pas optimale.

```
SOL_2_REC

Entrée : x et y deux mots

Sortie : alignement minimale de (x,y)

si n = o alors

retourner (x,mots_gaps(m))

si m = o alors

retourner (mots_gaps(n),y)

si n = 1 alors

retourner align_lettre_mot(x,y)

i = [n/2]

j = coupure(x,y,i)

(x1,y1) = SOL_2_REC(x[0...],y[0...])

(x2,y2) = SOL_2_REC(x[i+1..n],y[i+1..m])

Retourner(x1+x2,y1+y2)
```

#### **Question 25**

```
coupure
          Entrée : x et y deux mots
          Sortie : entier coupure de y
          n=|x|, m=|y|
          D = tableau indexé par [o..1][o..m]
          I = tableau indexé par [o..1][o..m]
          pour k de 1 à m+1 faire
                   |[o][k]=k
                    D[o][k]=k \times C_{del}
          pour i de 1 à n+1 faire
                   |[1][0]=0
                   D[1][0]=i \times C_{ins}
                    pour j de 1 a m+1 faire
                             dell=D[1][j-1] + C_{del}
                             ins =D[o][j] + C_{ins}
                             sub=D[o][j-1] + C_{sub}(x_{[i-1]},y_{[j-1]})
                             D[1][j]=min(dell,ins,sub)
                             si (i > n/2) alors
                                       Si (D[1][j]=dell) alors
                                                 |[1][j]=|[1][j-1]
                                       Sinon Si (D[1][j]=ins) alors
                                                 l[1][j]=l[o][j]
                                       Sinon
                                                 |[1][j]=|[0][j-1]|
                    D[o]=D[1]
                   si (i > n/2) alors
                             |[o]=|[1]
          retourner I[o][m]
```

#### **Question 26**

La complexité spatiale de coupure est en  $\Theta(m)$  cars seule deux tableau de deux dimension de taille m sont stockée.

#### **Question 27**

La complexité spatiale de SOL\_2 est en **©(m)** cars seule les deux tableaux de coupure de taille m sont stockée.

En prenant en compte la pile des appels récursifs : on sait que la complexité de coupure est en **O(m)** qui est en **O(n)** car n>m . Donc pour chaque appel récursive de SOL\_2 on a deux sous problème de taille n/2

Et pour chaque appel récursive on a une complexité spatiale en O(n)

Donc:  $T(n)=2\times T(n/2)+O(n)$ , a=2, b=2, d=1 On a  $\log_2(2)=1$  donc d'après le théorème de maitre:

 $T(n)=O(n\times log(n))$ 

#### **Question 28**

La complexité temporelle de coupure est en **O(n×m)** car on doit parcourir toute la matrice de taille n×m pour trouver la coupure.

#### Tache D

Les tests son indiquer sur le fichier testTacheC.py, les résultats son les suivants :

fichier: Instances\_genome/Inst\_0000010\_7.adn

Alignement methode 2: ('TGGGTG--CTAT', '-GGG-GTTCTAT') time used is 0.000267 s

fichier: Instances\_genome/Inst\_0000010\_8.adn

Alignement methode 2: ('AACTGTCTTT', 'AACTGT-TTT') time used is 0.000200 s

fichier: Instances\_genome/Inst\_0000010\_44.adn

Alignement methode 2: ('TATATGAGTC', 'TAT-T---T-') time used is 0.000148 s

fichier: Instances\_genome/Inst\_0000012\_32.adn

Alignement methode 2: ('CCATTGATTTTC', 'C-ATTGATTT--') time used is 0.000228 s

fichier: Instances\_genome/Inst\_0000012\_56.adn

Alignement methode 2: ('GCTTAACTAACG', 'GCTAAACTA-CT') time used is 0.000262 s

fichier: Instances genome/Inst 0000100 7.adn

Alignement methode 2: ('TGGGTGCGTG...CTCAGT', 'TGGGTTA...-CCTCA-T') time used is 0.010963 s

fichier: Instances\_genome/Inst\_0000500\_88.adn

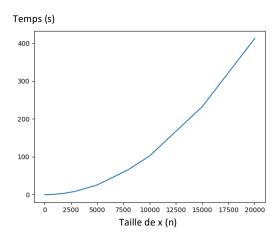
Alignement methode 2: ('TGT-CTCGG-...CAATTTCCA-G', '-GTTCT...TTT--AAG') time used is 0.247998 s

 $fichier: Instances\_genome/Inst\_0002000\_44.adn$ 

Alignement methode 2: ('TATATGA....-TGTCAGT', '-ATATGA....GTCAGA') time used is 3.917269 s

Consommation mémoire de SOL\_2: "Instances\_genome/Inst\_0020000\_5.adn" 17.5% soit 2,8 GB.

#### Complexité:



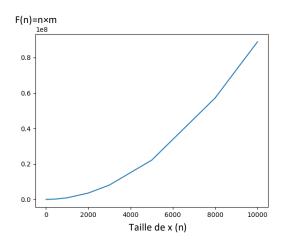
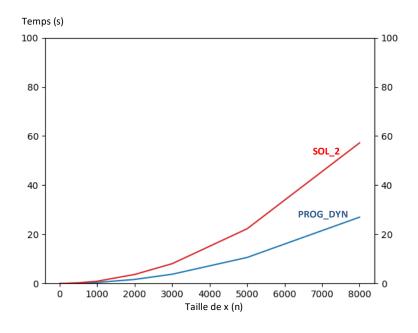


Figure 8 - Performance de SOL\_2

Figure 9 - Courbe théorique de ⊖(n×m)

SOL\_2 est supérieure a  $\Theta(n \times m)$  voir (entre 0 et 10000) mais inferieure a  $\Theta(n^2)$  mais largement en  $O(n^2)$ 

# **Question 29**



En comparant la complexité de PROG\_DYN et SOL\_2 on remarque qu'on a perdu en complexité temporelle en améliorant la complexité spatiale

Figure 10 - Comparaison entre PROG\_DYN et SOL\_2

# UNE EXTENSION: L'ALIGNEMENT LOCAL DE SEQUENCES (BONUS)

#### **Question 30**

En calculant le cout minimal des exemples suivants (inclus dans le répertoire BONUS) on obtient :

Pour  $Inst_1$ : n=20 , m=2 , DIST\_1 retourne 36 qui est bien 2 × (20-2) =  $C_{del}$  × (n-m)

Pour Inst\_2: n=25, m=4, DIST\_1 retourne qui est bien  $2 \times (25-4) = C_{del} \times (n-m)$ 

Pour Inst\_3: n=18, m=3, DIST\_1 retourne qui est bien  $2 \times (18-3) = C_{del} \times (n-m)$ 

Pour Inst\_4: n=40, m=9, DIST\_1 retourne qui est bien  $2 \times (40-9) = C_{del} \times (n-m)$ 

#### **Question 31**

C'est une bonne idée pour un alignement petit mais pour un alignement de taille max qui est de n+m on aura une complexité de  $(n+m)^2$  car on enlevant les gaps du début et fin on parcours tout de même  $(n+m) \times (n+m) \times (le \ cout \ d'aligner \ T[i][|y|]et \ T[|x|][j])$ 

# **COMPARAISON ENTRE LES PERFORMANCE DES ALGORITHMES**

Algorithme	Complexité temporelle	Complexité spatiale	Consommation mémoire
DIST_NAIF	$\Theta(\sum_{k=1}^{m}(C_{n+k}^{k}\times C_{n}^{k'}))$	⊝(1)	0.1%
DIST_1	⊝(n×m)	⊝(n×m)	69%
DIST_2	⊙ (n×m)	⊝(m)	17.5%
SOL_1	O(n+m)	O(n+m)	/
PROG_DYN	⊝(n×m)	⊝(n×m)	85%
Align_lettre_mot	⊝(m)	⊝(m)	/
Coupure	⊝(n×m)	⊝(m)	/
SOL_2	O(n²)	⊝(m)	17.5%

Les consommations mémoire sont calculer pour une taille n = 20000

#### **Conclusions:**

- DIST\_NAIF est la plus mauvaise méthode pour résoudre le problème malgré ca complexité spéciale en ⊖(1) mais le nombre d'appels récursifs est trop important et la capacité de la pile ne suffit pas pour une taille supérieure à 500.
- DIST\_2 est mieux que DIST\_1 en termes de complexité spatiale avec une augmentation négligeable de complexité temporelle à cause des décalages comme on voit sur la Figure 5.
- SOL\_2 est mieux que PROG\_DYN en termes de complexité spatiale pour un prix considérable de complexité temporelle.
- La consommation mémoire de SOL\_2 est similaire a celle de DIST\_2 car coupure utilise le même principe que DIST\_2.